
Predicción del éxito académico en educación superior

Álvaro Bilbao Pardo
Ingeniería Matemática e Inteligencia Artificial
Universidad Pontificia Comillas ICAI
Aprendizaje Automático, curso 2025–2026

Abstract

Este proyecto estudia la predicción del éxito académico en educación superior mediante técnicas de aprendizaje automático. A partir de información demográfica, académica, administrativa y socioeconómica de estudiantes, se abordan tres tareas: clasificación multiclase de la situación final del alumno, regresión de la nota media del segundo semestre y aprendizaje no supervisado para explorar perfiles internos. El trabajo presta especial atención a la limpieza de datos, la prevención de fuga de información, la selección de métricas adecuadas y la interpretación crítica de los resultados. Los mejores resultados se obtienen con KNN en clasificación, regresión lineal polinómica en regresión y una combinación de PCA y K-means en la parte no supervisada.

1. Introducción y objetivo del proyecto

El objetivo de este proyecto es construir y evaluar modelos de aprendizaje automático aplicados al estudio del éxito académico en educación superior. El conjunto de datos contiene información demográfica, académica, administrativa y socioeconómica de estudiantes, además de variables relacionadas con su rendimiento durante el primer y segundo semestre. A partir de esta información, se busca estudiar hasta qué punto es posible anticipar la trayectoria final del alumno y su rendimiento académico.

El trabajo se organiza en tres tareas complementarias. La primera es una tarea de clasificación multiclase, donde se intenta predecir si el estudiante termina en situación de abandono, matriculado o graduado. La segunda es una tarea de regresión, cuyo objetivo es predecir la variable `nota_media_2sem`, es decir, la nota media obtenida en el segundo semestre. La tercera es una tarea de aprendizaje no supervisado, centrada en explorar si existen perfiles de estudiantes o agrupaciones naturales dentro de los datos.

La idea principal no es únicamente obtener la métrica más alta posible, sino plantear el problema de forma correcta. Una buena métrica pierde valor si el modelo está mal formulado, si los datos han sido contaminados o si el conjunto de test se usa indirectamente para tomar decisiones. Por ello, se ha prestado especial atención al preprocesado, a la separación correcta entre entrenamiento y prueba y a una interpretación prudente de los resultados, recordando que las asociaciones encontradas por el modelo no implican necesariamente causalidad.

Como apoyo a la lectura, se incluye al final del documento un glosario con los principales conceptos de aprendizaje automático utilizados en el informe. Este glosario está pensado para facilitar la comprensión a lectores no necesariamente técnicos, como posibles clientes o responsables académicos.

2. Descripción del conjunto de datos

El dataset recoge información de estudiantes de educación superior organizada en varios bloques: variables demográficas y personales, variables de acceso y contexto académico previo, variables

socioeconómicas y administrativas, y variables de rendimiento académico del primer y segundo semestre. En conjunto, estas variables permiten describir tanto el perfil inicial del estudiante como algunas condiciones que pueden influir en su trayectoria académica.

Las variables académicas del primer y segundo semestre son especialmente informativas, ya que incluyen asignaturas matriculadas, evaluadas, aprobadas, sin evaluación y nota media. Sin embargo, requieren cuidado metodológico. En clasificación pueden ayudar a explicar la situación final del alumno, pero en regresión no deben usarse variables del segundo semestre demasiado cercanas a `nota_media_2sem`, porque introducirían fuga de información.

La variable objetivo de clasificación es `objetivo`, con tres clases: *abandono*, *matriculado* y *graduado*. Tras la limpieza, el dataset utilizado en el notebook quedó formado por 4403 observaciones y 37 variables. La distribución de clases no es uniforme: 2205 estudiantes graduados, 1406 en abandono y 792 matriculados, aproximadamente un 50.08 %, 31.93 % y 17.99 %, respectivamente. Por este desbalance, además de accuracy se utiliza F1 macro, que permite valorar mejor el rendimiento del modelo en todas las clases.

3. Exploración inicial y limpieza de los datos

Antes de entrenar modelos se realizó una limpieza inicial. Lo primero fue cargar el dataset y convertir el valor `en_blanco` en un verdadero valor nulo. Esta decisión es importante porque, si se deja como una cadena de texto, el modelo podría interpretarlo como una categoría válida. En ese caso, se estaría diciendo indirectamente que “en blanco” es una modalidad real de la variable, cuando en realidad representa ausencia de información.

Después se eliminaron únicamente las filas con ausencia en `ocupacion_madre` y `ocupacion_padre`. Al ser pocos casos, resultaba más razonable eliminarlos que introducir valores artificiales mediante imputación, especialmente en variables categóricas con muchas modalidades.

Una vez hecha esa limpieza, se revisaron tres aspectos básicos: valores nulos restantes, duplicados e incoherencias académicas. No quedaron columnas con nulos y tampoco había filas duplicadas. Esto permitió continuar sin aplicar una estrategia general de imputación.

Sin embargo, sí aparecieron algunos datos raros. Había 2784 casos en los que las asignaturas evaluadas del primer semestre eran superiores a las matriculadas, y 2652 casos similares en el segundo semestre. Aunque a primera vista parece una incoherencia, no se eliminaron automáticamente, porque pueden existir razones administrativas o de codificación, como convalidaciones, evaluaciones repetidas o registros que no coinciden exactamente con la idea intuitiva de “asignatura matriculada”.

También se encontraron casos con nota media igual a cero pese a tener asignaturas evaluadas: 363 en el primer semestre y 461 en el segundo. Aquí tampoco se eliminaron todos de forma automática. Una nota media de cero puede parecer extraña, pero puede representar estudiantes que se presentaron y no aprobaron, abandonos tempranos con evaluación registrada o situaciones académicas reales. El criterio seguido fue no borrar información solo porque sea incómoda para el modelo. En aprendizaje automático, los datos raros pueden ser errores, pero también pueden contener parte importante del fenómeno que se quiere estudiar.

La excepción se hizo en la tarea de regresión. Para predecir `nota_media_2sem`, se eliminaron los alumnos con `asignaturas_2sem_evaluadas` = 0. La razón es que, si un alumno no tiene asignaturas evaluadas en el segundo semestre, su nota media deja de ser comparable con la de un alumno que sí ha sido evaluado. En ese caso, el valor de la nota no representa exactamente el mismo concepto. Por tanto, mantener esos casos podía mezclar dos problemas distintos: predecir rendimiento académico y detectar ausencia de evaluación.

4. Preprocesado y decisiones metodológicas

El preprocesado fue una de las partes más importantes del trabajo. Un modelo puede ser técnicamente correcto y aun así producir conclusiones poco válidas si los datos se han tratado mal. Por eso, todas las transformaciones se hicieron intentando respetar una idea básica: el modelo no debe tener acceso a información que no tendría en una situación real.

Primero se separaron los datos en entrenamiento y prueba. Esta separación se hizo antes de ajustar escalas, codificaciones o hiperparámetros. Es una buena práctica porque el conjunto de test debe simular datos nuevos. Si se usa el test para calcular medias, desviaciones o columnas de codificación, se está filtrando información desde la prueba hacia el entrenamiento.

En clasificación, la partición fue estratificada por la variable objetivo. Como las clases no estaban equilibradas, era importante que entrenamiento y prueba mantuvieran proporciones parecidas de abandono, matriculado y graduado. Si no se hiciera así, el conjunto de test podría quedar con una distribución poco representativa, y la evaluación final dependería demasiado de la partición concreta.

Para las variables categóricas se usaron dos estrategias. En KNN se aplicó one-hot encoding completo, sin eliminar categorías. Esto tiene sentido porque KNN trabaja con distancias, y convertir una categoría en el vector de ceros puede introducir una asimetría artificial. En cambio, para la regresión logística y la regresión lineal se usó `drop_first=True`. En modelos lineales, eliminar una categoría de referencia ayuda a evitar colinealidad exacta y permite interpretar el resto de categorías respecto a una base.

También se estandarizaron las variables numéricas cuando el modelo lo necesitaba. Esta decisión fue especialmente importante en KNN, PCA y K-means. Estos métodos dependen de distancias o de varianza, por lo que una variable con valores mucho más grandes puede dominar el comportamiento del modelo aunque no sea realmente más importante. Estandarizar no cambia la información de la variable, solo la escala en la que se presenta al modelo.

En la tarea de clasificación se seleccionaron variables académicas, administrativas y personales relevantes. Se incluyeron variables del primer y segundo semestre porque el objetivo era predecir la trayectoria final del estudiante, no una variable concreta del segundo semestre. En ese contexto, la información del segundo semestre puede ayudar a explicar si el alumno acaba abandonando, sigue matriculado o se gradúa.

En la tarea de regresión el enfoque fue distinto. Como el objetivo era predecir `nota_media_2sem`, se excluyeron las variables del segundo semestre que estaban demasiado cerca del target. Por ejemplo, usar asignaturas aprobadas o evaluadas del segundo semestre podría convertir el problema en algo poco realista, porque esas variables se conocen al mismo tiempo que la nota o están muy relacionadas con ella. El objetivo era intentar anticipar el rendimiento del segundo semestre usando información previa: características de entrada, situación administrativa y rendimiento del primer semestre.

También se redujo la dimensión en KNN regresión. Se usó un subconjunto numérico formado por `nota_media_1sem`, asignaturas del primer semestre, nota previa, nota de admisión y edad. Esta reducción tiene sentido porque KNN puede sufrir en alta dimensión: cuando hay demasiadas variables, las distancias entre puntos pierden capacidad discriminativa y el concepto de vecino cercano se vuelve menos claro.

5. Tarea de clasificación

La primera tarea fue un problema de clasificación multiclase. La variable objetivo podía tomar tres valores: *abandono*, *matriculado* y *graduado*. Al no existir un orden natural entre estas clases, no tendría sentido tratar el problema como una regresión. Abandono no es “menor” que matriculado ni graduado está a una distancia numérica concreta de abandono. Por eso, la formulación correcta es clasificación.

Se compararon dos modelos: KNN y regresión logística multiclase. KNN es un modelo local y no paramétrico. Para clasificar una nueva observación, busca los k ejemplos más cercanos en el conjunto de entrenamiento y decide la clase por mayoría. Su ventaja es que puede adaptarse a formas de frontera no lineales sin imponer una estructura demasiado rígida. Su inconveniente es que depende mucho de la escala, de la dimensión y de la elección de k .

La regresión logística multiclase, por otro lado, es un modelo discriminativo. No clasifica por cercanía, sino que aprende una relación entre las variables y la probabilidad de cada clase. Es un modelo más estructurado y generalmente más interpretable, aunque puede quedarse corto si la frontera real entre clases es demasiado compleja.

Para KNN se realizó una búsqueda del mejor valor de k mediante validación cruzada estratificada con 5 folds, siempre dentro del conjunto de entrenamiento. La búsqueda se hizo por etapas, desde un

Cuadro 1: Selección de k en KNN de clasificación mediante validación cruzada.

Etapas	k	Accuracy media	F1 macro media	Desv. F1 macro
Barrido amplio	50	0.7278	0.6167	0.0106
Refinamiento intermedio	30	0.7303	0.6239	0.0163
Refinamiento fino	20	0.7346	0.6263	0.0117

Cuadro 2: Resultados de KNN en clasificación.

Métrica	Valor en test
Accuracy	0.7409
F1 macro	0.6411

barrido amplio hasta un ajuste fino alrededor de la mejor zona. El criterio principal fue F1 macro, ya que el problema está desbalanceado y no convenía elegir el modelo únicamente por accuracy.

El mejor valor final fue $k = 20$. Con este modelo, los resultados en test fueron los siguientes:

La matriz de confusión obtenida fue:

La matriz muestra que el modelo identifica muy bien a los graduados, pero tiene más dificultad con los matriculados. Esto es razonable porque matriculado es la clase minoritaria y, además, puede ser una clase intermedia. Un estudiante matriculado todavía no ha abandonado, pero tampoco se ha graduado, por lo que sus características pueden parecerse parcialmente a las de ambos grupos.

Después se entrenó una regresión logística multiclase como modelo de comparación. Este modelo obtuvo una accuracy de 0.7341 y un F1 macro de 0.5874. La accuracy fue parecida a la de KNN, pero el F1 macro fue claramente menor. Esto sugiere que la regresión logística acierta un porcentaje global similar, pero reparte peor el rendimiento entre clases. Es decir, puede estar funcionando bien para las clases más frecuentes, pero peor para alguna clase más difícil.

El mejor modelo de clasificación fue KNN. Aun así, la conclusión no debe ser que KNN sea siempre mejor, sino que en este dataset y con esta selección de variables capturó mejor la estructura entre las clases. La diferencia entre accuracy y F1 macro confirma que no basta con mirar el porcentaje de aciertos: en un problema educativo, detectar mal a un grupo minoritario también importa.

6. Tarea de regresión

La segunda tarea consistió en predecir `nota_media_2sem`. En este caso, la variable objetivo es numérica, por lo que el problema se planteó como regresión. A diferencia de la clasificación, aquí sí existe orden y distancia entre valores: no es lo mismo equivocarse por 0.5 puntos que por 4 puntos.

Antes de entrenar los modelos, se eliminaron los estudiantes con cero asignaturas evaluadas en el segundo semestre. Esta decisión fue necesaria porque la nota media de un alumno sin evaluaciones no representa lo mismo que la nota media de un alumno que sí ha sido evaluado. Mantener esos casos podía hacer que el modelo mezclas rendimiento académico con ausencia de evaluación.

Después se separaron entrenamiento y test mediante estratificación por rangos de nota. Para ello, la variable objetivo se dividió en grupos mediante cuantiles. La idea fue que tanto el conjunto de entrenamiento como el de test conservaran una distribución parecida de notas bajas, medias y altas. Esta estrategia reduce el riesgo de que el test quede artificialmente más fácil o más difícil.

En regresión se compararon dos enfoques: KNN regresión y regresión lineal ampliada. Para KNN se usó un conjunto reducido de variables numéricas, porque el modelo se basa en distancias. Las variables utilizadas fueron: `nota_media_1sem`, asignaturas aprobadas, evaluadas, matriculadas y sin evaluación del primer semestre, nota de la cualificación previa, nota de admisión y edad al matricularse. La idea era construir una predicción basada en información previa y razonablemente interpretable.

Para elegir k en KNN regresión se utilizó validación cruzada con 5 folds. La métrica principal fue RMSE, porque penaliza más los errores grandes. Esto tiene sentido en una predicción de notas: un

Cuadro 3: Matriz de confusión de KNN. Filas: clase real. Columnas: clase predicha.

	Abandono	Graduado	Matriculado
Abandono	184	65	32
Graduado	5	427	9
Matriculado	18	99	41

Cuadro 4: Comparación final de modelos de clasificación.

Modelo	Accuracy test	F1 macro test
KNN ($k = 20$)	0.7409	0.6411
Regresión logística	0.7341	0.5874

error pequeño puede ser aceptable, pero errores muy grandes pueden llevar a conclusiones poco útiles.

El mejor valor final fue $k = 27$. En test, KNN regresión obtuvo:

Estos resultados indican que el modelo explica una parte relevante de la variabilidad de la nota del segundo semestre. El MAE de 1.42 significa que, de media, el error absoluto ronda un punto y medio. El RMSE es mayor porque penaliza más los errores grandes, lo que indica que existen algunos casos en los que el modelo se equivoca bastante más.

Después se compararon varias variantes de regresión lineal: modelo base, modelo polinómico, modelo con interacciones y spline cúbico natural. Esta comparación responde a una idea importante: la regresión lineal base puede ser útil, pero a veces resulta demasiado rígida. Si la relación entre las variables y la nota no es puramente recta, puede ser necesario añadir curvatura, interacciones o términos más flexibles.

La variante polinómica añade términos cuadrados de algunas variables relevantes, como la nota media del primer semestre, asignaturas aprobadas, nota previa y nota de admisión. Esto permite capturar relaciones curvas sin abandonar del todo la estructura de modelo lineal. El modelo con interacciones intenta capturar situaciones en las que el efecto de una variable depende de otra, por ejemplo que el efecto de la nota previa cambie según la situación administrativa del alumno. El spline ofrece una alternativa más flexible para modelar la relación con la nota del primer semestre sin imponer una única forma global.

La elección se hizo mediante validación cruzada sobre entrenamiento:

La variante elegida fue la polinómica, porque obtuvo el mayor R^2 medio y el menor RMSE medio. Aunque su MAE no fue el menor, la mejora en R^2 y RMSE indica que capturó mejor la estructura global y redujo mejor los errores grandes.

Finalmente, se entrenó la variante polinómica con todo el entrenamiento y se evaluó una única vez en test. La comparación final fue:

La regresión lineal polinómica obtuvo mejor R^2 y menor RMSE, por lo que explicó algo mejor la variabilidad de la nota y redujo más los errores grandes. KNN, en cambio, obtuvo un MAE menor, lo que indica que su error absoluto medio fue ligeramente mejor. Esta diferencia muestra que no todas las métricas cuentan exactamente lo mismo: si se priorizan los errores grandes, la regresión polinómica es preferible; si se mira el error medio absoluto, KNN resulta muy competitivo.

En conjunto, la tarea de regresión muestra que el rendimiento del primer semestre contiene información útil para anticipar la nota del segundo semestre. Aun así, no debe confundirse predicción con causalidad: el modelo aprende asociaciones observadas, pero no demuestra por sí solo qué factor causa la mejora o el empeoramiento de la nota.

Cuadro 5: Selección de k en KNN regresión mediante validación cruzada.

Etapa	k	MAE medio	RMSE medio	R^2 medio
Barrido amplio	50	1.5337	2.8283	0.5564
Refinamiento intermedio	30	1.5263	2.7997	0.5652
Refinamiento fino	25	1.5264	2.7995	0.5652
Ajuste final	27	1.5250	2.7971	0.5660

Cuadro 6: Resultados de KNN regresión en test.

Métrica	Valor
MAE	1.4218
RMSE	2.5769
R^2	0.6445

7. Aprendizaje no supervisado

La tercera parte del trabajo fue un análisis no supervisado. Aquí no se usó la variable objetivo como respuesta, porque el objetivo no era predecir abandono o graduación, sino explorar si los estudiantes se agrupan de manera natural según sus características.

Se seleccionó un subconjunto de variables relacionadas con nota de admisión, nota de cualificación previa, edad al matricularse, rendimiento del primer semestre y algunas variables administrativas y personales como beca, deuda, matrícula al día, género, desplazamiento e internacionalidad. No se usó directamente la variable objetivo, porque eso convertiría el análisis en una lectura supervisada.

Antes de aplicar PCA y K-means, se preparó la matriz mediante codificación de categóricas y estandarización. Esta decisión es especialmente importante en aprendizaje no supervisado, porque no hay una métrica de error respecto a una etiqueta verdadera. Si las escalas están mal, el algoritmo puede construir grupos dominados por una variable simplemente porque tiene valores más grandes.

Primero se aplicó PCA manualmente. PCA busca nuevas direcciones, llamadas componentes principales, que capturan la mayor varianza posible. En este caso, la dimensión original después del preprocesado fue de 20 variables. Para conservar al menos el 80 % de la varianza explicada acumulada fueron necesarias 8 componentes principales.

Esta reducción tiene sentido porque permite trabajar con una representación más compacta de los datos. No significa que las 8 componentes sean fáciles de interpretar una a una, ya que cada componente es una combinación de variables originales. Sin embargo, sí permite reducir ruido, eliminar parte de la redundancia y facilitar el clustering.

Después se aplicó K-means sobre las componentes principales seleccionadas. Se probaron valores de K entre 2 y 6. Para evaluar cada solución se usaron dos criterios: inercia y silueta. La inercia mide qué tan compactos son los clusters, pero tiende a bajar al aumentar K . Por eso no basta con elegir el menor valor de inercia. La silueta, en cambio, tiene en cuenta tanto la cercanía dentro del cluster como la separación respecto a otros clusters.

El número de clusters elegido fue $K = 5$, ya que obtuvo la mayor silueta media. La diferencia con $K = 6$ fue muy pequeña, por lo que no conviene presentar el resultado como una verdad absoluta. En aprendizaje no supervisado, las agrupaciones tienen un componente exploratorio y dependen de las variables seleccionadas, la escala y la métrica utilizada.

La interpretación de los clusters debe hacerse como una ayuda para entender perfiles, no como una clasificación definitiva. Un cluster puede contener estudiantes de varias clases reales y aun así ser útil si agrupa observaciones con características parecidas. Una continuación razonable sería cruzar los clusters con la variable objetivo, una vez construidos los grupos, para analizar si algunos perfiles concentran mayor proporción de abandono o graduación. Esta lectura sería descriptiva, no causal, pero podría aportar información útil para una institución educativa.

Cuadro 7: Comparación de variantes lineales mediante validación cruzada.

Modelo	R^2 medio	RMSE medio	MAE medio
Polinómica	0.6116	2.6468	1.5696
Spline	0.5999	2.6864	1.5671
Interacciones	0.5997	2.6868	1.5620
Base	0.5996	2.6872	1.5611

Cuadro 8: Comparación final de modelos de regresión en test.

Modelo	R^2 test	RMSE test	MAE test
KNN regresión ($k = 27$)	0.6445	2.5769	1.4218
Regresión lineal polinómica	0.6691	2.4861	1.4682

8. Interpretación crítica de resultados

Los resultados obtenidos muestran que el dataset contiene información predictiva relevante, especialmente en las variables académicas del primer semestre y en algunas variables administrativas. En clasificación, KNN obtuvo mejores resultados que la regresión logística, especialmente en F1 macro. Esto sugiere que una estrategia basada en cercanía entre estudiantes fue capaz de capturar patrones que el modelo lineal no recogió con la misma eficacia.

La matriz de confusión permite ver que la clase más difícil fue *matriculado*. Esto tiene sentido desde el punto de vista del problema. Un estudiante matriculado puede parecerse a un graduado porque sigue en el sistema, pero también puede parecerse a un abandono si su rendimiento o situación administrativa es débil. Por tanto, no es una clase tan separada como podría parecer inicialmente.

En regresión, la regresión lineal polinómica fue el modelo más sólido si se atiende a R^2 y RMSE. La mejora respecto al modelo lineal base indica que introducir cierta curvatura ayuda a representar mejor la relación entre rendimiento previo y nota posterior. Esto encaja con la intuición de que la relación entre nota del primer semestre y nota del segundo no tiene por qué ser estrictamente lineal. Un alumno con una nota muy baja puede comportarse de forma distinta a uno con una nota media o alta, y los efectos no tienen por qué crecer siempre al mismo ritmo.

KNN regresión también funcionó bien, especialmente en MAE. Esto indica que, para muchos estudiantes, buscar perfiles parecidos permite estimar razonablemente su nota. Sin embargo, KNN puede sufrir cuando hay demasiadas variables o cuando algunos estudiantes tienen combinaciones poco frecuentes de características. Por eso fue razonable reducir el conjunto de variables en esta parte.

En la parte no supervisada, el uso de PCA y K-means permitió buscar una estructura interna sin utilizar directamente la etiqueta final. La silueta obtenida no fue muy alta, por lo que los clusters no deben interpretarse como grupos perfectamente separados. Más bien indican que existe cierta estructura, pero no una división tajante. Esto es normal en datos educativos: los perfiles de estudiantes suelen mezclarse y no siempre forman grupos limpios.

Una conclusión transversal del proyecto es que el rendimiento académico temprano parece tener mucho peso. Las variables del primer semestre aparecen como una señal importante tanto para anticipar la nota del segundo semestre como para entender la trayectoria final. Desde una perspectiva institucional, esto puede ser útil porque el primer semestre todavía permite tomar medidas de apoyo. Aun así, las predicciones deben entenderse como una señal orientativa, no como un juicio definitivo sobre el estudiante.

9. Conclusiones y limitaciones

En este trabajo se han desarrollado tres enfoques complementarios para estudiar el éxito académico en educación superior. La clasificación permitió predecir la situación final del estudiante, la regresión permitió estimar la nota media del segundo semestre y el aprendizaje no supervisado permitió explorar posibles perfiles internos.

Cuadro 9: Comparación de valores de K en K-means.

K	Inercia	Silueta
5	40061.6492	0.2654
6	36086.5455	0.2652
2	63260.4827	0.2624
4	48192.9474	0.2387
3	53972.5433	0.2239

En clasificación, el mejor modelo fue KNN con $k = 20$, con una accuracy de 0.7409 y un F1 macro de 0.6411. La regresión logística obtuvo una accuracy parecida, pero menor F1 macro, por lo que su rendimiento fue menos equilibrado entre clases. La clase matriculado fue la más difícil de identificar, probablemente por su carácter intermedio.

En regresión, la regresión lineal polinómica obtuvo el mejor R^2 y RMSE en test, con un R^2 de 0.6691 y un RMSE de 2.4861. KNN regresión obtuvo un MAE menor, lo que muestra que ambos enfoques tienen ventajas distintas. La regresión polinómica parece reducir mejor los errores grandes, mientras que KNN ofrece un error absoluto medio muy competitivo.

En aprendizaje no supervisado, PCA permitió reducir la dimensión de 20 variables a 8 componentes conservando al menos el 80 % de la varianza. Después, K-means con $K = 5$ obtuvo la mejor silueta entre las opciones probadas. Aun así, la silueta no fue muy alta, por lo que los clusters deben interpretarse como perfiles exploratorios y no como grupos cerrados.

Las principales limitaciones del trabajo son cuatro. Primero, las conclusiones son predictivas y descriptivas, no causales. Segundo, algunas variables académicas pueden tener interpretaciones administrativas complejas. Tercero, los modelos dependen de las variables seleccionadas y del preprocesado aplicado. Cuarto, el aprendizaje no supervisado tiene una parte subjetiva, especialmente en la elección de variables y del número de clusters.

En conjunto, el proyecto muestra que un buen análisis de machine learning no consiste solo en entrenar modelos, sino en construir una metodología coherente. Separar correctamente los datos, evitar fuga de información, elegir métricas adecuadas y analizar críticamente los resultados es tan importante como la métrica final obtenida.

Glosario

Nota: Este glosario se incluye únicamente con finalidad informativa para facilitar la lectura del informe a lectores que son «clientes». No forma parte del cuerpo principal de análisis del trabajo ni debe considerarse dentro del límite de páginas del documento.

Aprendizaje supervisado. Tipo de aprendizaje en el que se tienen datos de entrada y una respuesta correcta asociada a cada observación. La idea es aprender una relación entre las variables explicativas y la variable objetivo para poder predecir casos nuevos.

Aprendizaje no supervisado. Tipo de aprendizaje en el que no existe una respuesta correcta conocida. Solo se dispone de las variables de entrada y el objetivo es descubrir estructura interna, patrones o agrupaciones dentro de los datos.

Clasificación. Tarea supervisada en la que la variable objetivo es categórica. En este proyecto se utiliza para predecir si un estudiante abandona, continúa matriculado o se gradúa.

Regresión. Tarea supervisada en la que la variable objetivo es numérica. En este trabajo se utiliza para predecir la nota media del segundo semestre.

EDA. Análisis exploratorio de datos. Es la fase inicial en la que se revisa el dataset, se analizan distribuciones, se detectan valores ausentes, duplicados, posibles incoherencias y relaciones importantes entre variables.

Preprocesado. Conjunto de transformaciones que se aplican a los datos antes de entrenar los modelos. Incluye limpieza, tratamiento de datos raros, codificación de variables categóricas, estandarización y selección de variables.

One-hot encoding. Técnica para convertir variables categóricas en columnas binarias. Cada categoría se representa mediante una columna y cada observación activa con un 1 la categoría que le corresponde.

Estandarización. Transformación de variables numéricas para que tengan media 0 y varianza 1. Es especialmente importante en modelos basados en distancias o varianzas, como KNN, PCA y K-means.

Data leakage. Fuga de información. Se produce cuando el modelo utiliza información que no debería estar disponible en el momento real de la predicción o que contiene indirectamente la variable objetivo.

Validación cruzada. Técnica para evaluar modelos usando distintas particiones del conjunto de entrenamiento. Permite elegir hiperparámetros de forma más estable sin mirar directamente el conjunto de test.

Overfitting. Sobreajuste. Ocurre cuando el modelo aprende demasiado bien los datos de entrenamiento, incluyendo ruido, y luego falla al predecir datos nuevos.

Underfitting. Subajuste. Ocurre cuando el modelo es demasiado simple y no consigue capturar la estructura real de los datos.

PCA. Análisis de Componentes Principales. Técnica no supervisada de reducción de dimensionalidad que busca nuevas direcciones que conserven la mayor varianza posible de los datos.

Clustering. Técnica no supervisada que agrupa observaciones similares entre sí. No parte de clases conocidas, sino que intenta descubrir grupos naturales en los datos.

K-means. Algoritmo de clustering que divide las observaciones en K grupos intentando que cada punto quede cerca del centroide de su cluster.

Inercia. Medida usada en K-means que resume la suma de distancias internas de los puntos a sus centroides. Cuanto menor es, más compactos son los clusters, aunque no siempre implica mejor solución.

Silueta. Métrica de clustering que tiene en cuenta la cohesión dentro del cluster y la separación respecto a otros clusters. Valores mayores indican grupos mejor definidos.

References

- [1] Departamento de Aprendizaje Automático. *Proyecto Final: Predicción del éxito académico en educación superior*. Curso académico 2025/2026.
- [2] Bilbao Pardo, A. *VersionFinalMachine*. Notebook desarrollado para el proyecto final de Aprendizaje Automático.
- [3] Bilbao Pardo, A. *Tema 2: Algoritmos de Machine Learning*. Apuntes de la asignatura Aprendizaje Automático.
- [4] Bilbao Pardo, A. *Tema 3: Técnicas específicas en Regresión*. Apuntes de la asignatura Aprendizaje Automático.
- [5] Bilbao Pardo, A. *Tema 4: Aprendizaje No Supervisado*. Apuntes de la asignatura Aprendizaje Automático.
- [6] Pedregosa, F. et al. Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 2011.
- [7] OpenAI. *ChatGPT*. Herramienta utilizada como apoyo para traducir y maquetar el contenido del informe en código L^AT_EX. También para citar las referencias.